Übungen Advanced SQL

Klaus-Georg Deck

2025-08-05

Einleitung

In diesem Skript findest du typische SQL-Übungen mit Beispielcode und den erwarteten Ergebnistabellen. Ziel ist es, fortgeschrittene SQL-Techniken wie Outer Join, Group-by, Aggregationen und einfache Subselects zu erlernen und zu vertiefen.

Die Aufgaben 6, 7 und 8 behandeln komplexere Subselects und sind optional.

Voraussetzungen

Du verfügst über einen Zugang zu einem Datenbank-Server (Oracle oder Postgres) mit den Tabellen des Bike-Verleih-Szenarios und hast Grundkenntnisse in SQL, etwa indem Du die vorherigen Übungen erfolgreich absolviert hast.

Aufgabe 1: Verknüpfung von Tabellen

a) Einfache OUTER-Join Anweisung

Für diesen Übungsteil benötigst Du die Tabellen EMPLO und SHOP. Gib eine SQL-Anweisung an, die den Namen der Mitarbeitenden zusammen mit dem Namen des Shops, dem sie zugeordnet sind, anzeigt. Es sollen alle Mitarbeitenden angezeigt werden, auch jene, die keinem Shop angehören. In diesem Fall soll der Wert des Shop-Namens leer sein. Sortiere die Datensätze nach ID aus EMPLO absteigend.

Die Resultatmenge hat folgende Gestalt:

ID	ENAME	SNAME
16055	Leon	
16051	Bea	
16050	Felix	Vaduz CyclePoint
16049	Anna	Bern Rollt

Lösung:

```
SELECT E.ID, E.NAME ENAME, S.NAME SNAME
FROM EMPLO E
LEFT OUTER JOIN SHOP S ON E.SHOP = S.ID
ORDER BY E.ID DESC
```

b) Vergleich zwischen OUTER- und INNER-Join

Ersetzst Du in der Lösung der vorherigen Teilaufgabe LEFT OUTER JOIN durch JOIN, dann sind die Resultate unterschiedlich. Zeige dies, indem Du in beiden Fällen die Anzahl der Datensätze ermittelst. Was kann man grundsätzlich über die Anzahl der Datensätze in solchen Fällen aussagen? Welche Datensätze kommen in welchem Resultat nicht vor?

Verwende anschliessend als Verknüpfung FULL OUTER JOIN. Wie viele Datensätze erhält man dann?

Verwende einen Teil der Lösung der vorherigen Teilaufgabe:

```
SELECT E.ID, E.NAME ENAME, S.NAME SNAME
FROM EMPLO E
LEFT OUTER JOIN SHOP S ON E.SHOP = S.ID
```

Lösung:

Die Anzahl der Datensätze beim LEFT OUTER JOIN ist 24, beim INNER JOIN ist sie 22 und beim FULL OUTER JOIN ist sie 25.

```
SELECT COUNT(*)
FROM EMPLO E
LEFT OUTER JOIN SHOP S ON E.SHOP = S.ID;

SELECT COUNT(*)
FROM EMPLO E
INNER JOIN SHOP S ON E.SHOP = S.ID;

SELECT COUNT(*)
FROM EMPLO E
FROM EMPLO E
FULL OUTER JOIN SHOP S ON E.SHOP = S.ID;
```

Wie Du Dich leicht überzeugen kannst, gibt es genau 22 Mitarbeitende, die einem Shop zugeordnet sind, 2 Mitarbeitende, die keinem Shop zugeordnet sind und genau ein Shop, dem keine Mitarbeitende zugeordnet sind.

Die Datensätze des Inner-Join sind in der Resultatmenge des LEFT OUTER-Join enthalten, der mehr Datensätze haben kann, nämlich die Datensätze der ersten (linken) Tabelle, für die die On-Bedingung nicht zutrifft. Bei einem RIGHT OUTER-Join kommen möglicherweise Datensätze der zweiten (rechten) Tabelle hinzu. Betrachtet man die Anzahl der Datensätze, so ist die Anzahl eines Inner-Join kleiner oder gleich der Anzahl des entsprechenden LEFT OUTER-Join sowie des RIGHT OUTER-Join und die Anzahl der Datensätze des FULL-Join ist grösser oder gleich der Anzahl des LEFT OUTER- resp. RIGHT OUTER-Join. Der FULL OUTER-Join enthält die Datensätze des Inner Join sowie die der linken und der rechten Tabelle, für die die On-Bedingung nicht zutrifft.

c) Join: INNER, LEFT, RIGHT, FULL und OUTER

Begründe, warum ein LEFT INNER- oder RIGHT INNER-Join keinen Sinn macht und warum bei LEFT OUTER-, RIGHT OUTER- und FULL OUTER-Join das Schlüsselwort OUTER weggelassen werden kann. Erstelle eine Übersichtstabelle, in der die jeweilige Lang- und Kurzform der verschiedenen Joins aufgelistet sind.

Lösung:

Die Resultatmenge eines INNER-Join ist von der Reihenfolge der Verknüpfung unabhängig, d.h. die Anweisung SELECT ... FROM A JOIN B ergibt bei gleicher ON-Bedingung das gleiche Resultat

wie SELECT ... FROM B JOIN A (die Reihenfolge der Attribute oder der Datensätze kann variieren). Daher macht die Verwendung von LEFT oder RIGHT hier keinen Sinn.

Die folgende Tabelle stellt die verschiedenen Verknüpfungen mit ihrer Kurzform dar:

Verknüpfung	Kurzform	Bemerkung
INNER JOIN	JOIN	symmetrisch
LEFT OUTER JOIN	LEFT JOIN	
RIGHT OUTER JOIN	RIGHT JOIN	
FULL OUTER JOIN	FULL JOIN	symmetrisch
CROSS JOIN	, (Komma)	keine ON-Bedingung

Aus jeder Kurzform ergibt sich eindeutig die Verknüpfung, da LEFT resp. RIGHT nur bei den nicht symmetrischen OUTER-Verknüpfungen Sinn macht, und ein JOIN allein, also ohne LEFT, RIGHT oder FULL dann zwangsläufig ein INNER JOIN ist.

Aufgabe 2: Verknüpfungen

Für diese Aufgabe benötigst Du die Tabellen CUSTOMER, RENTAL und BIKE, die Informationen über Bike-Ausleihen von Kunden enthalten.

a) Einfache Verknüpfung

Welche Kunden haben am 2. Januar 2025 oder früher Bikes ausgeliehen? Gib die Ausleih-ID, den Namen des Kunden und das Ausleihdatum, sortiert nach Ausleih-ID an. Das erwartete Resultat:

R_ID	NAME	DATUM
60023	Emma	2025-01-01
60046	Lena	2025-01-02
60078	Francesco	2025-01-01

Lösung:

```
SELECT R.ID R_ID, C.NAME, R.RENTAL_DATE DATUM
FROM RENTAL R
JOIN CUSTOMER C ON R.CUSTOMER = C.ID
WHERE RENTAL_DATE <= DATE '2025-01-02'
ORDER BY R.ID
```

b) Kunden mit und ohne Ausleihen

Welche Kunden haben bisher (irgendwann einmal) Bikes ausgeliehen?

Welche Kunden haben bisher noch keine Bikes ausgeliehen?

Gib jeweils die Kunden-ID und den Namen der Person an, aufsteigend sortiert nach Kunden-ID.

Tipp:

Verwende für den ersten Teil die vorherige Teilaufgabe. Beachte, dass Kunden nicht mehrfach genannt werden sollen. Für den zweiten Teil kann man einen LEFT JOIN verwenden und diejenigen Datensätze aus dem Resultat herausfiltern, für die die ON-Bedingung nicht zutrifft.

Alternative Lösungen: Verwendung SQL-Mengenoperationen (siehe spätere Übungen).

Lösung:

Kunden, die Bikes ausgeliehen haben:

```
SELECT DISTINCT C.ID, C.NAME
FROM RENTAL R
JOIN CUSTOMER C ON R.CUSTOMER = C.ID
ORDER BY C.ID;
```

Kunden, die bisher noch keine Bikes ausgeliehen haben:

```
SELECT C.ID, C.NAME
FROM CUSTOMER C
LEFT JOIN RENTAL R ON R.CUSTOMER = C.ID
WHERE R.CUSTOMER IS NULL
ORDER BY C.ID;
```

c) Anzahl der Kunden

Wie viele Kunden gibt es insgesamt, wie viele haben ein Bike des Modells 'Pathway' ausgeliehen und wie viele haben kein solches Modell ausgeliehen?

Formuliere SQL-Anweisungen, mit denen die ersten beiden Fragen beantwortet werden können. Die Antwort der dritten Frage kannst Du dann (ohne SQL) mittels Subtraktion ermitteln. Alternativ wird in *Aufgabe 7* eine weitere Lösung vorgestellt.

Lösung:

Insgesamt gibt es 167 Kunden, von denen 14 (mindestens einmal) ein Bike eines solchen Modells ausgeliehen haben. Demnach gibt es 153 Kunden, die bisher noch nie ein solches Bike ausgeliehen haben.

```
-- Alle Kunden

SELECT COUNT(*) AS CT FROM CUSTOMER;

-- Kunden die ein 'Pathway' ausgeliehen haben

SELECT COUNT(DISTINCT CUSTOMER) AS CT_PW

FROM RENTAL R

JOIN BIKE B ON R.BIKE = B.ID

WHERE B.MODELL = 'Pathway'
```

Aufgabe 3: Gruppierung und Aggregatsfunktionen

a) Average: Gehalt und Tage im Unternehmen

Gib eine SQL-Anweisung an, die das Durchschnitts-Gehalt und die Durchschnitts-Zeit im Unternehmen aller Mitarbeitenden ausgibt. Das Gehalt soll gerundet auf ganze Werte, die Zeit im Unternehmen gerundet als ganze Tage ausgegeben werden.

Zusätzlich soll angegeben werden, wie viele Mitarbeitenden es insgesamt gibt und wie viele jeweils in die Gehalts- resp. Zeit-Berechnung einfliessen. Beachte, dass fehlende Werte (NULL) bei den meisten Aggregatsfunktionen ignoriert werden.

Das Ergebnis sieht wie folgt aus:

CT_ALL	AVG_SAL	CT_SAL	AVG_DAYS	CT_DAYS
24	5'457	23	1'119	21

Lösung:

```
SELECT

COUNT(*) CT_ALL,

ROUND( AVG( SALARY ) ) AVG_SAL,

COUNT( SALARY ) CT_SAL,

ROUND( AVG( TRUNC(CURRENT_DATE - HIRE_DATE )) ) AVG_DAYS ,

COUNT( HIRE_DATE) CT_DAYS

FROM EMPLO
```

Der Ausdruck AVG(TRUNC(CURRENT_DATE - HIRE_DATE)) kann wie folgt vereinfacht werden:

```
Postgres: AVG( CURRENT_DATE - HIRE_DATE )
Oracle: AVG( TRUNC(CURRENT_DATE) - HIRE_DATE )
```

b) Average: Gehalt und Tage im Unternehmen pro Shop

Ermittle die gleichen Kennzahlen wie in der vorherigen Teilaufgabe, jedoch nicht für das gesamte Unternehmen, sondern pro Shop, dem die Mitarbeitenden zugeordnet sind. Gib dazu zusätzlich die Shop-ID aus und sortiere die Ausgabe nach der Shop-ID.

Das Resultat hat die folgende Form:

SHOP_ID	CT_ALL	AVG_SAL	CT_SAL	AVG_DAYS	CT_DAYS
10	4	5'157	4	1'300	3
12	4	5'425	4	935	4

Lösung:

```
SELECT
SHOP SHOP_ID,
COUNT(*) CT_ALL,
ROUND( AVG( SALARY ) ) AVG_SAL,
COUNT( SALARY ) CT_SAL,
ROUND( AVG( TRUNC(CURRENT_DATE - HIRE_DATE )) ) AVG_DAYS ,
COUNT( HIRE_DATE) CT_DAYS
FROM EMPLO
GROUP BY SHOP
ORDER BY SHOP
```

c) Average: Mehr Gehalt als der Durchschnitt

Gebe eine SQL-Anweisung an, die ermittelt, wer mehr als der Durchschnitt verdient. Von den Mitarbeitenden soll die ID, der Name, das Salär, die Shop-ID ausgegeben werden, sortiert nach ID

Gebe in einer weiteren SQL-Anweisung zusätzlich in jedem Datensatz das Durchschnittsgehalt (gerundet) aus.

Tipp: Verwende einfachen Subselect, der den Durchschnitt ermittelt.

Lösung:

```
SELECT ID, NAME, SALARY, SHOP FROM EMPLO
WHERE SALARY > (SELECT AVG(SALARY) FROM EMPLO)
ORDER BY ID;

SELECT ID, NAME, SALARY, SHOP, ROUND(AVG_S) AS AVG_S FROM emplo
JOIN (SELECT AVG(SALARY) AVG_S FROM EMPLO)
ON SALARY > AVG_S
ORDER BY ID;
```

Aufgabe 4: Mehrere GROUP-BY Attribute

Diese Aufgabe befasst sich mit den Bike-Ausleihen aus der Tabelle RENTAL. Beachte, dass Bikes mehrmals ausgeliehen werden können. Beantworte mittels SQL-Anweisungen die folgenden Fragen:

- Wie viele Ausleihen gab es pro Jahr und Monat und wie viele Bikes wurden pro Jahr und Monat ausgeliehen?
- Wie viele Ausleihen gab es pro Jahr, Monat und Shop, und wie viele Bikes wurden pro Jahr, Monat und Shop ausgeliehen?

Das Ergebnis soll jeweils die beteiligten Gruppierungsattribute sowie die Anzahl Bikes enthalten. Die Ausgabereihenfolge erfolgt nach den Gruppierungsattributen.

Das erwartete Resultat sieht wie folgt aus:

RENTAL_YEAR	RENTAL_MONTH	CT_RENTALS	CT_BIKES
2025	1	40	27
2025	2	31	25

RENTAL_YEAR	RENTAL_MONTH	SHOP	CT_RENTALS	CT_BIKES
2025	1	10	2	2
2025	1	12	13	8
•••			•••	

Tipps: Mit EXTRACT(YEAR FROM RENTAL_DATE) kann man das Jahr aus einem Datumswert ermitteln, analog mit MONTH auch den Monat.

Der Shop einer Ausleihe lässt sich ermitteln, indem man beachtet, welchem Shop das ausgeliehene Bike zugeordnet ist.

Lösung:

```
SELECT

EXTRACT(YEAR FROM RENTAL_DATE) RENTAL_YEAR,

EXTRACT(MONTH FROM RENTAL_DATE) RENTAL_MONTH,

COUNT(*) CT_AUSLEIHEN,

COUNT(DISTINCT BIKE) CT_BIKES

FROM RENTAL R
```

```
GROUP BY RENTAL_YEAR, RENTAL_MONTH
ORDER BY RENTAL_YEAR, RENTAL_MONTH;

SELECT

EXTRACT (YEAR FROM RENTAL_DATE) RENTAL_YEAR,
EXTRACT (MONTH FROM RENTAL_DATE) RENTAL_MONTH,
SHOP,
COUNT (*) CT_RENTALS,
COUNT (DISTINCT BIKE) CT_BIKES
FROM RENTAL R
JOIN BIKE B ON B.ID = R.BIKE
GROUP BY RENTAL_YEAR, RENTAL_MONTH, SHOP
ORDER BY RENTAL_YEAR, RENTAL_MONTH, SHOP;
```

Aufgabe 5: GROUP-BY und HAVING

Welche Bikes wurden vor dem 4. März 2025 mindestens 3 mal ausgeliehen?

Formuliere zunächst eine SQL-Anweisung, mit der die Bike-ID und die Häufigkeit der Ausleihe für das jeweilige Bike ausgegeben wird.

In einer weiteren SQL-Anweisung soll die Bike-ID, das Modell und die Häufigkeit ausgegeben werden. Die Reihenfolge soll jeweils nach Bike-ID erfolgen.

Lösung:

Zunächst lassen sich mit der HAVING-Klausel Gruppierungen mittels Aggregatfunktionen filtern.

```
SELECT BIKE, COUNT(*) CT
FROM RENTAL R
WHERE R.RENTAL_DATE < DATE '2025-03-04'
GROUP BY BIKE
HAVING COUNT(*)>3
```

Jetzt benötigt man noch den Modellnamen, den man über eine Verknüpfung mit der Tabelle BIKE erhält:

```
SELECT BIKE B_ID, MODELL, CT

FROM BIKE

JOIN

( SELECT BIKE, COUNT(*) CT

FROM RENTAL R

WHERE R.RENTAL_DATE < DATE '2025-03-04'

GROUP BY BIKE

HAVING COUNT(*)>3

) T ON T.BIKE = BIKE.ID

ORDER BY T.BIKE
```

Resultat:

B_ID	MODELL	CT
000-0	Loadster	4
30040	TrailKing	4

Die folgenden Aufgaben verwenden komplexere SQL-Anweisungen, wie z.B. korrelierte Subselects, und sind optional.

Aufgabe 6: Subselect und GROUP BY (optional)

Beantworte via SQL-Anweisungen die folgenden Fragen:

- An welchem Tag wurden erstmals Bikes ausgeliehen? Gib von allen Ausleihen, die an diesem Tag getätigt wurden, die ID, die Bike-ID und das Datum aus.
- Welche Kunden haben die meisten Ausleihen getätigt? Gib alle diese Kunden (Customer-ID) aus, zusammen mit der Anzahl der Ausleihen.
- Welche Kunden haben die meisten Bikes ausgeliehen? Gib alle diese Kunden (Customer-ID) aus, zusammen mit der Anzahl entliehener Bikes.

Lösung:

Beachte, dass es mehrere solche Ausleihen geben kann. Daher wäre eine Lösung, die den ersten Datensatz aus einer nach Ausleihdatum aufsteigend sortierten Liste auswählt, nicht korrekt.

```
SELECT ID, BIKE, RENTAL_DATE FROM RENTAL
WHERE RENTAL_DATE = (SELECT MIN(RENTAL_DATE) FROM RENTAL);

-- alternative Lösung: Ausleihen, zu denen es keine früheren gibt
SELECT T.ID, T.BIKE, T.RENTAL_DATE FROM RENTAL T
LEFT JOIN RENTAL T_NOTEXIST
ON T.RENTAL_DATE > T_NOTEXIST.RENTAL_DATE
WHERE T_NOTEXIST.ID IS NULL;
```

Für die Lösung der zweiten Teilaufgabe betrachten wir die folgende Anweisung, die pro Kunde/Kundin die Anzahl seiner/ihrer Ausleihen ermittelt:

```
SELECT CUSTOMER, COUNT(*) CT_RENTALS
FROM RENTAL R
GROUP BY CUSTOMER
```

Da diese Anweisung in der gesuchten Anweisung mehrmals auftritt, geben wir ihr als *Common Table Expression* (CTE) den Namen CT_CUST und können diesen Ausdruck wie einen gewöhnlichen Tabellennamen mehrmals verwenden.

Der Vollständigkeit wegen hier die SQL-Anweisung ohne Verwendung von WITH. An der Markierung erkennt man die genannte SELECT-Anweisung:

```
SELECT CUSTOMER, CT_RENTALS
FROM
-->(SELECT CUSTOMER, COUNT(*) CT_RENTALS
--> FROM RENTAL R GROUP BY CUSTOMER)
WHERE CT_RENTALS =
  ( SELECT MAX(CT_RENTALS) FROM
   -->(SELECT CUSTOMER, COUNT(*) CT_RENTALS
```

```
--> FROM RENTAL R GROUP BY CUSTOMER)
)
ORDER BY CUSTOMER;
```

Die Lösung für die dritte Teilaufgabe besteht darin, in der vorherigen Anweisung COUNT(*) durch COUNT(DISTINCT BIKE) zu ersetzen.

Die Resultate sind:

CUSTOMER	CT_RENTALS
50136	6
50151	6

CUSTOMER	CT_BIKES
50117	4
50118	4
50136	4

Aufgabe 7: Subselect und OUTER JOIN (optional)

Wie viele Kunden gibt es insgesamt, wie viele haben ein Bike des Modells 'Pathway' ausgeliehen und wie viele haben kein solches Modell ausgeliehen?

Formuliere eine einzige SQL-Anweisung, welche diese Frage beantwortet. (In $Aufgabe\ 2\ c)$ wurden diese Fragen bereits beantwortet.)

Tipp: Selektiere alle Kunden und füge via LEFT JOIN Informationen über Ausleihen von Bikes des genannten Modells hinzu.

Lösung:

Die erste SQL-Anweisung ermittelt (eindeutige) Kunden-IDs von Kunden, welche die gesuchten Bikes ausgeliehen haben:

```
SELECT DISTINCT CUSTOMER

FROM RENTAL

JOIN BIKE B ON BIKE = B.ID

WHERE MODELL = 'Pathway'
```

Dieser Ausdruck lässt sich nun in der Lösung einbringen, indem man ihn via LEFT JOIN an die Tabelle CUSTOMER anspielt. Das Resultat verwendet die Eigenschaft der Aggregatsfunktion COUNT(), die für ein angegebenes Attribut alle von NULL verschiedenen Werte zählt:

```
SELECT COUNT(ID) CT, COUNT(CUSTOMER) CT_PW, COUNT(ID)-COUNT(CUSTOMER) CT_NO_PW
FROM CUSTOMER
LEFT JOIN
(SELECT DISTINCT CUSTOMER
FROM RENTAL
JOIN BIKE B ON BIKE = B.ID
WHERE MODELL = 'Pathway'
) BIKE_RENTED
ON ID = CUSTOMER
```

Aufgabe 8: Subselect pro Gruppierung (optional)

Formuliere SQL-Anweisungen, mit denen alle Mitarbeitenden ausgegeben werden, die *mindestens so viel* wie der Durchschnitt der Mitarbeitenden des *gleichen Shops* erhalten. Von den Mitarbeitenden soll die ID, der Name, das Salär, die Shop-ID und das Durchschnittsgehalt für den Shop (gerundet) ausgegeben werden, sortiert nach ID.

Tipp:

Orientiere Dich an $Aufgabe\ 3c)$ und formuliere zunächst eine SQL-Anweisung, die Shop-ID und Durchschnittsgehalt pro Shop ermittelt. Diese Anweisung kann man via JOIN an die Tabelle EMPLO anspielen.

Lösung:

Wir beginnen mit dem Ermitteln des Durchschnittsgehalts pro Shop:

```
SELECT SHOP, AVG(SALARY)
FROM EMPLO
GROUP BY SHOP
```

Nun verknüpft man jede Datenzeile aus EMPLO mit dem Resultat dieses SELECT, das für den passenden Shop das Durchschnittsgehalt liefert.

```
SELECT ID, NAME, SALARY, E.SHOP FROM EMPLO E

JOIN (SELECT SHOP, AVG(SALARY) AVG_SAL_SH

FROM EMPLO

GROUP BY SHOP) SUBSEL

ON SUBSEL.SHOP = E.SHOP

WHERE SALARY >= AVG_SAL_SH
```

Da die Subselect-Anweisung bereits das Durchschnittsgehalt pro Shop ermittelt, lässt sich das Attribut AVG_SAL_SH einfach in die SELECT-Klausel der Gesamtanweisung aufnehmen. Ergänzt werden muss die ON-Bedingung noch um den Zusatz, dass - wenn man die Aufgabenstellung so verstehen möchte - auch Mitarbeitende ohne Shop-Zuordnung ausgegeben werden, sofern sie mindestens so viel verdienen, wie der Durchschnitt aller solcher Mitarbeitenden.

Du kannst Dich gerne vom Effekt dieses Zusatzes überzeugen, indem Du ihn wahlweise aktiviert oder deaktivierst.

```
SELECT ID, NAME, SALARY, E.SHOP, ROUND(AVG_SAL_SH) AVG_SAL_SH FROM EMPLO E

JOIN (SELECT SHOP, AVG(SALARY) AVG_SAL_SH
FROM EMPLO
GROUP BY SHOP) SUBSEL

ON SUBSEL.SHOP = E.SHOP
--die folgende Zeile aktivieren/deaktivieren
--OR (SUBSEL.SHOP IS NULL AND E.SHOP IS NULL)

WHERE SALARY >= AVG_SAL_SH
```

Alternative Lösungen kann man auch mit korrelierten Subselect-Anweisungen erhalten.